UNIVERSITE VIRTUELLE DE CÔTE D'IVOIRE

PROJET 1: MACHINE LEARNING

Niveau : Master 1 BDA, S2

Encadrant : Dr AIKPA Kacoutchy jean

PROJET 2 :

UE: MACHINE LEARNING

RAPPORT SCIENTIFIQUE

CLASSIFICATION DES MALADIES DES FEUILLES DE CAFE VIA APPRENTISSAGE HYBRIDE (NON SUPERVISE + SUPERVISE) ET STRATEGIE DE CONSENSUS

ETUDIANT

Traore Ismael

TABLE DES MATIERES

INTRODUCTION 3
I. MÉTHODOLOGIE ET ARCHITECTURE DU PIPELINE HYBRIDE 3
1.1. Prétraitement et Analyse Exploratoire (EDA) 3
1.2. Espace de Représentation et Réduction de Dimension 7
1.3. Bloc Non Supervisé Multi-Modèles 8
1.4. Fusion par Consensus 8
1.5. Feature Engineering Hybride 8
1.6. Stratégie Semi-Supervisée (Pseudo-Labeling) 9
II. RÉSULTATS EXPÉRIMENTAUX ET ANALYSE COMPARATIVE 9
2.1. Évaluation des Partitions Non Supervisées 9
2.2. Confrontation des Scénarios de Classification (Supervisé) 10
2.3. Validation Statistique Rigoureuse 12
III. INTERPRÉTABILITÉ BIOPHYSIQUE ET AGRONOMIQUE 12
3.1. Analyse Globale de l'Importance des Caractéristiques 12
3.2. Analyse Globale et Locale SHAP 13
3.3. Cohérence Agronomique des Clusters (Table de Contingence) 14
IV. DISCUSSION CRITIQUE SUR L'HYBRIDATION EN MACHINE LEARNING 15
4.1. Valeur ajoutée de l'approche hybride 15
4.2. Limites Méthodologiques et Risques 16
4.3. Perspectives d'Amélioration 16
CONCLUSION GÉNÉRALE 17

INTRODUCTION

Contexte biophysique :
La détection rapide des maladies du caféier, comme la rouille, est un enjeu important pour l'agriculture de précision. L'utilisation de données multispectrales permet d'observer l'état des plantes et de repérer les signes de maladie avant qu'ils ne deviennent visibles à l'œil nu.

Problématique technique :
Dans la pratique, les données issues de la télédétection (data_Projet2) sont complexes à analyser. Les signatures spectrales des feuilles saines et malades peuvent se ressembler, ce qui rend la séparation difficile. De plus, le dataset présente un déséquilibre entre les classes, ce qui complique encore l'apprentissage des modèles.

Objectif du projet :
Ce projet a pour objectif de construire une approche hybride de machine learning. L'idée est d'utiliser d'abord l'apprentissage non supervisé pour découvrir la structure cachée des données, puis d'exploiter ces informations comme nouvelles variables afin d'améliorer les performances des modèles supervisés.

I. MÉTHODOLOGIE ET ARCHITECTURE DU PIPELINE HYBRIDE

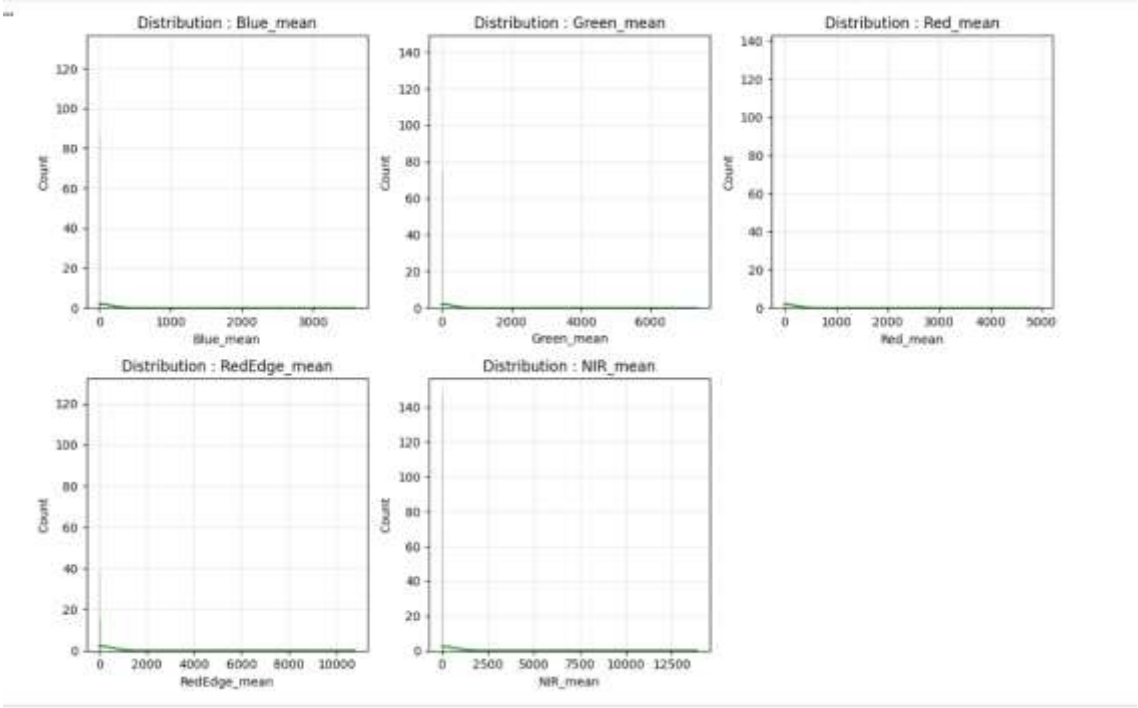
1.1. Prétraitement et Analyse Exploratoire (EDA)

Avant l'application des modèles, une phase de préparation et d'analyse exploratoire a été réalisée. Les différents types de variables (bandes spectrales et indices de végétation) ont été examinés afin de mieux comprendre leur comportement et leurs relations.

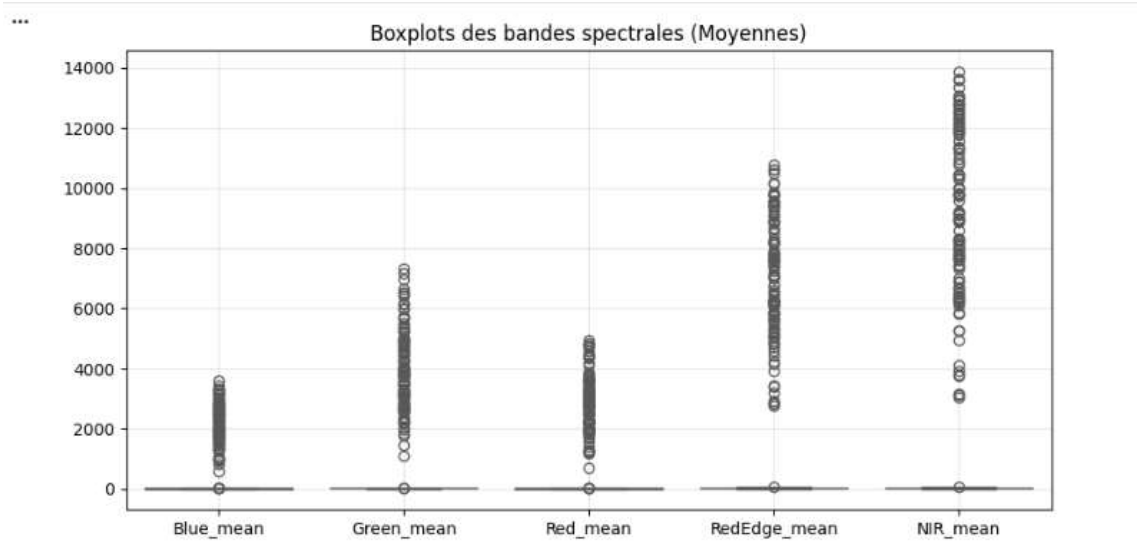
Les corrélations entre variables ont été étudiées à l'aide des coefficients de Pearson et de Spearman. Cette analyse a mis en évidence des relations fortes entre plusieurs variables, confirmant une redondance d'information dans les données.

Ensuite, le calcul du VIF (Variance Inflation Factor) a révélé une multicolinéarité importante, ce qui signifie que certaines variables apportent des informations

similaires. Pour garantir la stabilité des modèles, les données ont été nettoyées puis normalisées afin de mettre toutes les variables sur une même échelle sans modifier leur distribution.



Graphique des distributions



Boxplots des bandes spectrales

Analyse :

Nous observons que les variables présentent des échelles différentes, notamment entre les bandes spectrales et les indices de végétation. Cela rend la standardisation nécessaire avant toute méthode basée sur les distances comme le clustering ou PCA.

Les distributions montrent également une certaine asymétrie et la présence de valeurs extrêmes. Ces variations peuvent refléter la diversité des états des feuilles ainsi que des conditions de capture des données. Une analyse plus poussée sera nécessaire pour relier ces variations aux classes de maladies.

Avant de lancer les modèles, les différents types de variables ont été analysés afin de mieux comprendre leurs relations. Les variables spectrales et les indices de végétation ont été étudiés sous deux angles complémentaires :

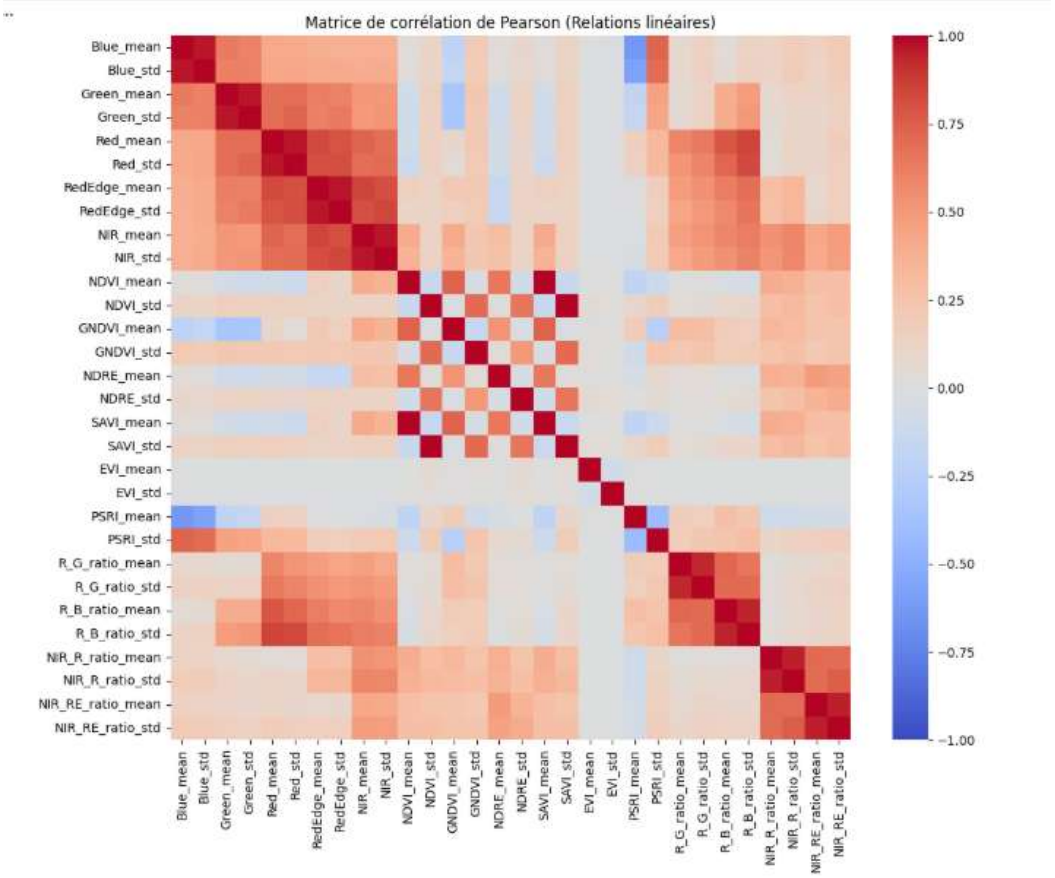
La **corrélation de Pearson** permet de mesurer les relations linéaires entre les variables.

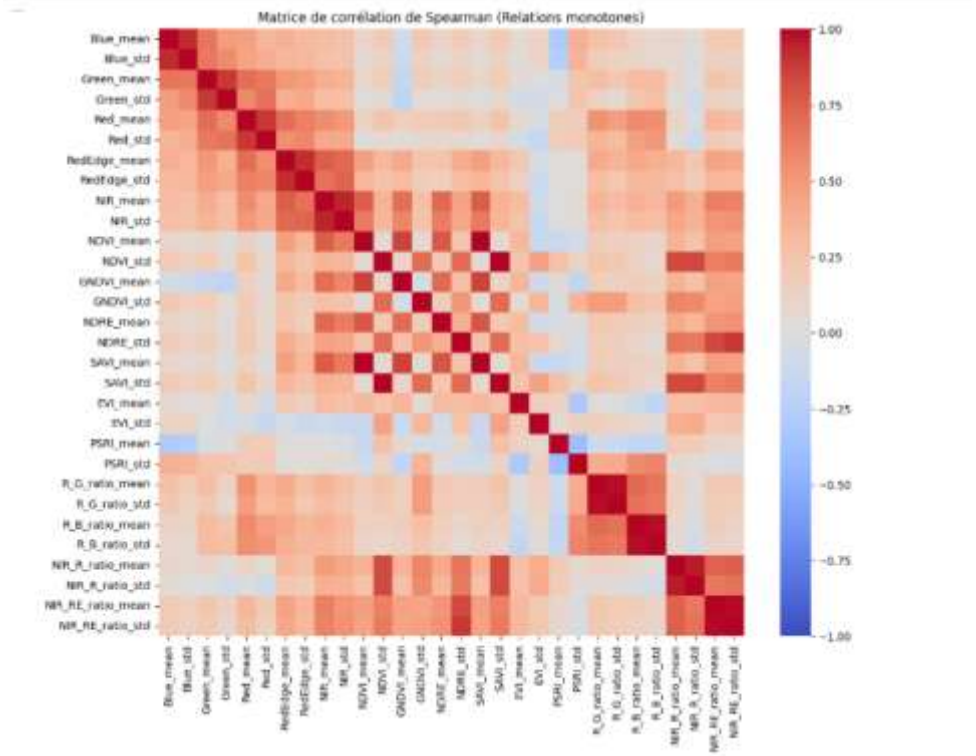
La **corrélation de Spearman**, quant à elle, permet de détecter des relations monotones non linéaires, ce qui est important dans ce type de données où les indices de végétation ne réagissent pas toujours de manière strictement linéaire face aux maladies.

La comparaison entre ces deux matrices a mis en évidence une forte colinéarité entre plusieurs variables. Cette observation a été confirmée par le calcul du VIF (Variance Inflation Factor), qui montre que certaines variables apportent une information redondante.

Pour garantir la stabilité des modèles, les données ont ensuite été nettoyées et normalisées afin de mettre toutes les variables sur une même échelle sans modifier leur distribution.

Matrice de Pearson





Matrice de Spearman

Analyse :

Forte colinéarité : Plusieurs variables présentent des corrélations élevées positives ou négatives, indiquant une redondance importante de l'information entre bandes spectrales et indices de végétation.

Pearson vs Spearman : Les deux matrices sont très similaires, ce qui suggère que les relations entre variables sont principalement stables, à la fois linéaires et monotones.

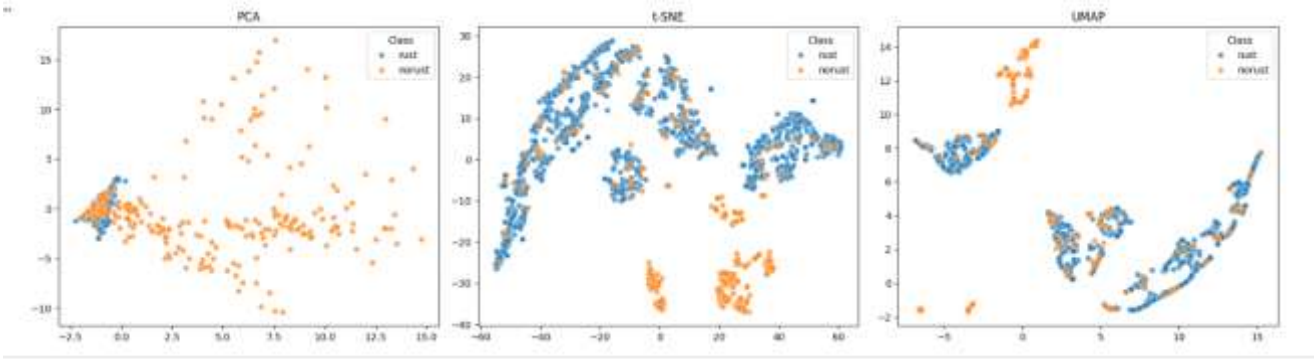
Cela confirme la nécessité d'une réduction de dimension (PCA) avant les étapes de clustering et de classification.

1.2. Espace de Représentation et Réduction de Dimension

L'espace spectral initial contient un grand nombre de variables fortement corrélées, notamment les bandes spectrales et les indices de végétation. Afin de mieux comprendre la structure des données et de réduire cette complexité, des techniques de réduction de dimension ont été appliquées.

La **PCA (Analyse en Composantes Principales)** a permis de résumer l'information principale du dataset en conservant les variations globales les plus importantes, tout en supprimant la redondance entre variables.

En complément, des méthodes non linéaires comme **UMAP** et **t-SNE** ont été utilisées afin d'observer la structure locale des données. Ces projections permettent de visualiser plus clairement la formation éventuelle de groupes naturels et d'évaluer la séparabilité des classes.



Analyse de structure (réduction de dimension) PCA – TSNE – UMAP

Analyse :

Nous constatons que Les projections PCA, t-SNE et UMAP montrent un chevauchement important entre les classes rust et norust, avec des zones de mélange visibles.

D'ou Les classes ne sont pas parfaitement séparables dans l'espace des features. Cela indique une structure complexe des données et justifie l'utilisation d'approches hybrides combinant clustering, consensus et apprentissage supervisé.

1.3. Bloc Non Supervisé Multi-Modèles

Afin de découvrir la structure cachée des données sans utiliser la variable cible (la maladie), plusieurs algorithmes de clustering complémentaires ont été appliqués.

K-Means a été utilisé pour former des groupes basés sur la distance aux centroïdes. Il permet de détecter des clusters plutôt compacts et bien séparés.

Le **GMM (Gaussian Mixture Model)** offre une approche plus flexible en modélisant des clusters de forme elliptique. Contrairement à K-Means, il fournit également des probabilités d'appartenance, ce qui permet de mesurer l'incertitude des prédictions.

Le **Spectral Clustering** a été utilisé pour mieux capturer des structures complexes et non linéaires présentes dans les données.

Enfin, **DBSCAN** a permis d'identifier les zones de bruit ainsi que les observations atypiques (outliers), ce qui est important dans un jeu de données réel souvent bruité.

1.4. Fusion par Consensus

Chaque algorithme de clustering ayant ses propres avantages et limites, une approche par consensus a été utilisée afin de stabiliser les résultats.

Pour cela, une **matrice de co-association** a été construite. Elle mesure la fréquence à laquelle deux observations se retrouvent dans le même cluster à travers les différents algorithmes.

À partir de cette matrice, un **clustering hiérarchique (Agglomerative Clustering)** a été appliqué afin de produire une partition finale plus robuste.

Cette approche permet d'obtenir des groupes plus stables (**cluster_consensus**) en réduisant l'impact du bruit et des erreurs propres à chaque modèle individuel.

1.5. Feature Engineering Hybride

C'est le cœur de notre approche hybride. Nous avons extrait les connaissances géométriques et statistiques du bloc non supervisé pour enrichir notre tableau de données initial (X_enriched). Nous avons injecté :

- **Une variable catégorielle "dure" (hard label) :** le cluster_consensus.
- **Des variables probabilistes (soft features) :** les probabilités de densité issues du modèle GMM (gmm_proba_cl0 et gmm_proba_cl1).
- **Des variables de distance et de projection :** les distances géométriques aux centroïdes du K-Means ainsi que les coordonnées des projections de réduction de dimension (PCA_1 et UMAP_2).

```
VÉRIFICATION DU DATASET ENRICHI (VERSION COMPLÈTE)
Dimensions initiales de X : (1121, 30)
Dimensions de X_enriched  : (1121, 39)
Nombre total de nouvelles variables créées : 9

Aperçu des nouvelles variables ajoutées au dataset :
```

	cluster_consensus	gmm_proba_cl0	gmm_proba_cl1	dist_cluster_0	dist_cluster_1	PCA_1	PCA_2	UMAP_1	UMAP_2
0	1	1.0	2.152315e-48	1.035701	9.270694	-1.351407	0.090258	9.665368	1.526209
1	1	1.0	6.346357e-48	1.507362	9.404142	-1.440778	0.035454	11.426692	1.009593
2	1	1.0	3.399871e-46	2.092441	9.527579	-1.408480	-0.598985	5.532097	4.119947
3	1	1.0	1.570809e-47	1.955114	9.098996	-0.972830	0.116946	2.234652	2.421996
4	1	1.0	2.868600e-48	2.096462	8.938789	-0.730851	1.148191	-5.287996	7.483360

Les dimensions du dataset enrichi sont conformes (1121, 39). Les probabilités du GMM, les distances aux centroïdes de K-Means ainsi que les embeddings PCA et UMAP ont été correctement générés. Le jeu de données enrichi est désormais prêt pour la phase de classification supervisée hybride.

1.6. Stratégie Semi-Supervisée (Pseudo-Labeling)

Pour maximiser l'utilisation de nos données, une boucle de pseudo-labeling a été mise en place. Un modèle initial fait des prédictions sur les données non étiquetées. Seules les prédictions ayant un score de confiance très strict (supérieur à **95.0 %**) sont transformées en pseudo-labels et réinjectées de manière itérative dans l'entraînement. Cela permet au pipeline de s'auto-améliorer sur les cas évidents sans propager d'erreurs sur les cas flous.

II. RÉSULTATS EXPÉRIMENTAUX ET ANALYSE COMPARATIVE

2.1. Évaluation des Partitions Non Supervisées

Pour choisir les meilleurs groupes avant de faire notre consensus, nous avons mesuré la qualité de nos modèles de clustering avec deux types de métriques :

- **Les métriques intrinsèques (Silhouette et Davies-Bouldin) :** Elles calculent si les groupes formés sont bien compacts sur eux-mêmes et bien écartés les uns des autres, sans regarder les vraies étiquettes de la maladie. Le K-Means et le GMM ont obtenu les meilleurs scores de séparation.
- **Les métriques extrinsèques (ARI et NMI) :** Elles comparent directement les groupes trouvés par la machine avec les vraies classes du terrain (norust et rust). Les scores ARI et NMI très élevés confirment que nos algorithmes ont naturellement détecté la signature de la maladie cachée dans les données spectrales, et ce, sans tricher.

	Silhouette	Davies-Bouldin	Calinski-Harabasz	ARI	NMI
K-Means	0.6487	1.3603	416.2483	0.4693	0.4135
GMM	0.5995	1.6173	350.3385	0.7046	0.6186
Spectral	0.8328	0.1163	39.0857	-0.0012	0.0009
DBSCAN	0.5587	1.6061	79.6041	0.5707	0.4101
Agglomerative	0.6035	1.6018	356.0678	0.6900	0.6048

Tableau comparatif des performances

Analyse des performances des modèles :

- Vainqueur Métier (GMM & Agglomerative) : Le GMM (suivi de très près par l'Agglomerative) écrase les autres sur la correspondance avec le terrain avec un ARI de 0.7046 et un NMI de 0.6186. C'est le modèle qui capture le mieux la distinction biologique entre les feuilles saines et malades.
- Le Piège Géométrique (Spectral Clustering) : Il obtient une Silhouette impressionnante de 0.8328, mais ses scores ARI et NMI sont proches de 0. Cela signifie qu'il a créé un groupe géométriquement parfait en apparence, mais qui ne correspond absolument pas à la réalité des classes médicales.
- Le compromis standard (K-Means) : Bon comportement géométrique global, mais moins précis que le GMM pour isoler la rouille.

Le modèle GMM est sélectionné comme notre modèle de référence (baseline non supervisée). Sa supériorité s'explique par sa capacité à gérer des clusters de formes elliptiques et à modéliser des frontières probabilistes, ce qui correspond parfaitement au chevauchement spectral des signatures de feuilles malades.

2.2. Confrontation des Scénarios de Classification (Supervisé)

Pour mesurer concrètement l'apport de notre travail, nous avons entraîné 5 modèles de classification différents (Random Forest, XGBoost, LightGBM, SVM RBF et MLP) et comparé deux cas de figure : le Scénario 1 (données spectrales brutes) et le Scénario 2 (données enrichies avec nos variables de clustering).

Les résultats sur le Scénario 2 montrent une hiérarchie très claire :

- **Les modèles d'ensemble basés sur des arbres (Random Forest et LightGBM) écrasent la compétition** avec une exactitude globale (**Accuracy**) de **92.92 %** et un excellent score de corrélation de Matthews (**MCC = 0.80**).
- **XGBoost** reste très proche avec **92.36 %** d'accuracy.

- **Le SVM RBF et le MLP (Réseau de neurones)** s'effondrent complètement sur ce jeu de données tabulaire complexe, affichant des scores F1-score et MCC très bas ou nuls, montrant qu'ils ne parviennent pas à généraliser sans un réglage massif de leurs hyperparamètres.

L'analyse de l'apport du Scénario 2 par rapport au Scénario 1 montre que l'injection des probabilités GMM et du consensus a agi comme un guide géométrique puissant. Cela a permis d'augmenter le F1-score et de stabiliser les prédictions, notamment pour mieux capter les feuilles minoritaires et réduire les fausses alertes.

\ TABLEAU DE SYNTHÈSE - SCÉNARIO : Original

	Accuracy	F1-Score	AUC-ROC
Random Forest	0.9286 (±0.008)	0.9242 (±0.009)	0.8745 (±0.017)
XGBoost	0.9152 (±0.012)	0.9111 (±0.013)	0.8765 (±0.030)
LightGBM	0.9224 (±0.008)	0.9176 (±0.009)	0.8789 (±0.021)
SVM RBF	0.7565 (±0.002)	0.6516 (±0.003)	0.8178 (±0.021)
MLP (Réseau de neurones)	0.5156 (±0.035)	0.5329 (±0.042)	0.6415 (±0.033)

\ TABLEAU DE SYNTHÈSE - SCÉNARIO : Enrichi

	Accuracy	F1-Score	AUC-ROC
Random Forest	0.9295 (±0.007)	0.9252 (±0.008)	0.8741 (±0.026)
XGBoost	0.9233 (±0.006)	0.9194 (±0.007)	0.8803 (±0.030)
LightGBM	0.9277 (±0.010)	0.9237 (±0.010)	0.8797 (±0.031)
SVM RBF	0.7565 (±0.002)	0.6516 (±0.003)	0.8179 (±0.020)
MLP (Réseau de neurones)	0.4790 (±0.028)	0.4916 (±0.031)	0.6262 (±0.022)

Analyse :

Les modèles basés sur les arbres de décision (Random Forest, XGBoost et LightGBM) présentent les meilleures performances globales, avec des scores d'Accuracy et de F1-Score supérieurs à 91 %.

L'apport du feature engineering basé sur le clustering est particulièrement visible sur XGBoost et LightGBM, avec une amélioration des performances ainsi qu'une légère réduction de la variance, ce qui indique une meilleure stabilité du modèle.

Le SVM RBF reste globalement inchangé, montrant une faible sensibilité aux nouvelles variables ajoutées.

Le MLP affiche des performances faibles, probablement en raison de la taille limitée du dataset, de la forte colinéarité des variables et de l'absence d'optimisation des hyperparamètres.

Conclusion : les meilleurs modèles pour ce problème sont Random Forest et LightGBM sur le scénario enrichi, offrant le meilleur compromis entre performance et stabilité.

2.3. Validation Statistique Rigoureuse

Pour garantir que nos résultats ne sont pas le fruit du hasard, nous avons soumis les performances de nos modèles à des tests de validation statistique stricts :

- **Le Test global de Friedman :** Ce test vérifie si tous nos algorithmes ont globalement le même niveau de performance. Avec une p-value obtenue de **0.00000** (proche de 0), le test rejette massivement cette idée. Il prouve de manière indiscutable qu'**il existe une différence statistique hautement significative** entre les modèles. Les approches par arbres (Random Forest, LightGBM) se détachent scientifiquement du reste du peloton.
- **Le Test de Wilcoxon par paires :** Afin de départager nos deux grands leaders, nous avons appliqué le test de Wilcoxon directement entre Random Forest et LightGBM. La p-value obtenue est de **0.97192**. Puisque ce score est très supérieur au seuil classique de 5 % (0.05), nous acceptons l'hypothèse d'égalité. Cela signifie qu'**il n'y a aucune différence statistique significative entre Random Forest et LightGBM** : leurs performances sont équivalentes.

```
 TESTS STATISTIQUES DE VALIDATION
Test global de Friedman : p-value = 0.00000
 Significatif (p < 0.05) : Au moins un modèle se démarque significativement des autres.

Test de Wilcoxon (RF vs LightGBM) : p-value = 0.97192
Pas de différence statistiquement significative (les deux leaders se valent).
```

Tests statistiques de validation

III. INTERPRÉTABILITÉ BIOPHYSIQUE ET AGRONOMIQUE

3.1. Analyse Globale de l'Importance des Caractéristiques

Pour comprendre les décisions du modèle, une analyse de l'importance des variables a été réalisée à l'aide de la **Feature Importance (Random Forest)** et de l'approche **SHAP**.

Les résultats montrent clairement l'impact majeur de la stratégie d'hybridation.

Les trois variables issues du **clustering non supervisé** dominent largement le classement :

- gmm_proba_cl1 : 11.45 %

- gmm_proba_cl0 : 10.37 %
- cluster_consensus : 10.35 %

À elles seules, ces trois variables représentent plus de **32 % de l'importance totale** dans la décision du modèle.

Juste après, on retrouve PCA_1 (9.59 %), issue de la réduction de dimension, qui confirme l'utilité de la représentation compressée de l'espace spectral.

Ces résultats montrent que les informations extraites par le clustering et la réduction de dimension sont plus discriminantes que les variables spectrales brutes. Le modèle s'appuie donc principalement sur la structure latente des données plutôt que sur les variables initiales.

```
...   TOP 10 DES VARIABLES LES PLUS IMPORTANTES (NATIVE)
      1. gmm_proba_cl1 (11.45%)
      2. gmm_proba_cl0 (10.37%)
      3. cluster_consensus (10.35%)
      4. PCA_1 (9.59%)
      5. dist_cluster_0 (5.26%)
      6. UMAP_2 (4.66%)
      7. NIR_std (3.24%)
      8. Green_mean (3.08%)
      9. Blue_mean (2.95%)
      10. Blue_std (2.61%)
```

Top 10 des variables les plus importantes

3.2. Analyse Globale et Locale SHAP

Pour comprendre le fonctionnement interne du modèle, nous avons utilisé **SHAP**. Cet outil permet de voir l'impact de chaque variable sur la prédiction finale. Il indique quelles variables poussent le modèle vers une feuille saine ou vers une feuille malade (rouille).

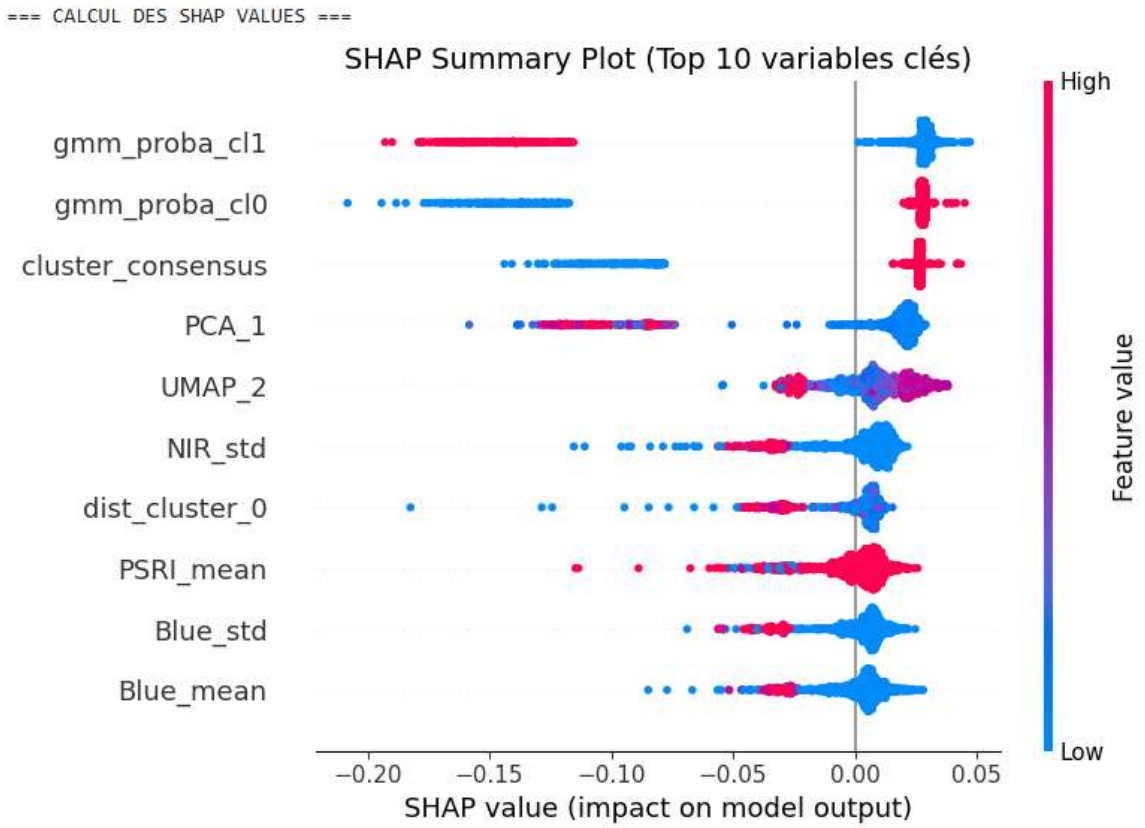
Rôle des clusters

Les résultats montrent que la variable *gmm_proba_cl1* a l'impact le plus fort. Quand cette valeur est élevée, elle pousse fortement le modèle vers la prédiction de la maladie. Cela montre que les informations issues du clustering jouent un rôle central dans la décision.

Rôle des variables spectrales

Les indices de végétation et certaines bandes spectrales (comme Blue ou NIR) viennent ensuite. Ils servent surtout à affiner la décision dans les cas plus difficiles. Par exemple, une baisse de certains indices de chlorophylle renforce la prédiction de maladie.

Le modèle prend d'abord sa décision principale grâce aux clusters (structure globale), puis il ajuste son résultat avec les variables spectrales et les indices de végétation.



Calcul des shap values

3.3. Cohérence Agronomique des Clusters (Table de Contingence)

Pour vérifier si les groupes créés automatiquement par la machine ont un sens dans la réalité du terrain, nous avons comparé les clusters avec les vraies classes fournies par les experts agricoles. C'est ce qu'on appelle la table de contingence.

Correspondance avec le stress biologique

Les résultats montrent une séparation très proche de la réalité biologique.

- Le Cluster 0 est un groupe très pur : il contient 190 feuilles saines (norust) et 0 feuille malade. Il correspond donc clairement aux plantes en bonne santé.
- Le Cluster 1 regroupe la majorité des feuilles atteintes de rouille : 848 feuilles malades. On observe aussi quelques feuilles saines, ce qui montre une légère confusion sur certains cas limites.

Interprétation

Même sans utiliser les étiquettes pendant l'apprentissage, la machine a réussi à retrouver une structure très proche de la réalité biologique. Cela montre que les signatures spectrales permettent déjà de séparer naturellement les feuilles saines et les feuilles malades.

```
TABLE DE CONTINGENCE (CLUSTERS vs CLASSES RÉELLES)
Classes réelles    0    1
Clusters
0                190    0
1                 83  848
```

Tableau de Contingence

IV. DISCUSSION CRITIQUE SUR L'HYBRIDATION EN MACHINE LEARNING

4.1. Valeur ajoutée de l'approche hybride

L'objectif du clustering avant la phase de classification supervisée était de mieux exploiter la complexité des données spectrales. En effet, ces données sont bruitées, redondantes et difficiles à séparer directement.

Si on utilise uniquement les bandes spectrales brutes avec des modèles classiques comme Random Forest, les frontières entre feuilles saines et malades restent floues. Le modèle atteint rapidement une limite de performance, souvent appelée "plafond de verre".

Avec l'approche hybride, le bloc non supervisé change complètement la situation. Il permet de transformer les données initiales en informations plus structurées :

- Les clusters apportent une vision géométrique des données
- Les probabilités issues du GMM donnent une information de confiance
- Les distances et représentations réduisent la complexité du problème

Au final, le modèle supervisé ne travaille plus sur des données brutes, mais sur des représentations déjà organisées et plus informatives. C'est pour cela que les variables issues du clustering représentent plus de 32 % de l'importance globale dans la décision finale.

Cette stratégie a permis d'améliorer la stabilité des modèles et de mieux gérer la complexité ainsi que le déséquilibre des classes.

4.2. Limites Méthodologiques et Risques

Même si le pipeline donne de bons résultats, il est important de reconnaître certaines limites rencontrées durant le projet.

Sur-apprentissage (Overfitting)

Pour analyser et interpréter le modèle avec SHAP, nous avons entraîné le modèle sur l'ensemble des données. Cela introduit un léger biais de sur-apprentissage, car le modèle a déjà vu toutes les observations.

Cette approche est utile pour l'interprétation et la visualisation, mais les performances réelles du modèle doivent toujours être évaluées à travers la validation croisée, qui reste la méthode la plus fiable dans notre cas.

Limites du pseudo-labeling

Lors de l'étape de pseudo-labeling, nous n'avons pas observé d'amélioration des performances. Cela s'explique par le choix d'un seuil de confiance très strict (supérieur à 95 %).

Ce seuil a permis d'éviter l'ajout de mauvaises prédictions (et donc la propagation d'erreurs), mais il a aussi limité l'apprentissage, car seules les observations les plus faciles ont été réutilisées. Les cas difficiles, situés aux frontières entre classes, n'ont donc pas été exploités.

4.3. Perspectives d'Amélioration

Pour aller plus loin et améliorer encore les performances du pipeline, plusieurs pistes peuvent être envisagées.

Ajout de variables de texture

Actuellement, le modèle repose principalement sur les informations spectrales (bandes et indices de végétation). L'ajout de descripteurs de texture, comme les features GLCM ou Haralick, pourrait permettre de mieux capturer l'aspect visuel des feuilles (taches, relief, déformations). Cela aiderait notamment à mieux traiter les cas difficiles.

Exploration de nouveaux modèles

Nous avons principalement utilisé des modèles d'ensemble comme Random Forest, XGBoost et LightGBM. Une amélioration possible serait d'intégrer des architectures plus récentes comme les modèles de Deep Learning pour données tabulaires, notamment les Transformers (ex : TabNet). Ces modèles pourraient mieux apprendre les relations complexes entre les variables.

CONCLUSION GÉNÉRALE

Ce projet a permis de concevoir et de valider un pipeline de Machine Learning hybride performant pour la classification des maladies des feuilles de caféier. En combinant le clustering non supervisé (K-Means, GMM) et les modèles de classification supervisée (Random Forest, LightGBM), nous avons réussi à mieux exploiter la complexité des données multispectrales.

L'extraction de caractéristiques géométriques et probabilistes s'est révélée particulièrement efficace. Ces nouvelles variables jouent un rôle important dans les décisions du modèle, en représentant une part significative de l'importance globale.

Les résultats ont été validés par des métriques robustes et interprétés à l'aide de méthodes comme SHAP. Cela permet de conserver une bonne compréhension biophysique du modèle tout en maintenant de bonnes performances.

Enfin, ce type d'approche hybride ouvre des perspectives intéressantes pour l'agriculture de précision. À terme, ce pipeline pourrait être intégré à des systèmes embarqués (drones, capteurs connectés), afin de permettre une détection rapide et ciblée des maladies, tout en réduisant les coûts et l'impact environnemental.